ESTUDIO TÉCNICO-FINANCIERO Y MODELO DE ESCALABILIDAD

Análisis de Costos de Inferencia IA, Despliegue en AWS y Estrategia de Almacenamiento Institucional

1. Premisas Clave y Matices Técnicos de la Arquitectura

Para garantizar un modelo de costos real, sostenible y defendible institucionalmente, se establecen los siguientes principios de ingeniería:

- **Almacenamiento Institucional Preexistente ($0 USD en Cloud Storage):** La gran mayoría de colegios públicos y privados ya cuentan con infraestructura de CCTV en sitio (grabadores NVR/DVR locales Hikvision, Dahua o servidores NAS con discos duros ya amortizados). NEXIA no fuerza al colegio a duplicar gastos subiendo terabytes a la nube: se conecta directamente a los flujos y grabaciones locales mediante protocolos estándar (RTSP/ONVIF). Por ende, el almacenamiento base se considera **cubierto por la institución**.
- **Salvedad de Almacenamiento Cloud Opcional:** Si una institución carece de NVR local o exige custodia externa como respaldo judicial en la nube, se cotiza como un *Add-on contingente* en AWS S3 con retención rotativa de 30 días (~$150 USD/mes).
- **Transición de Supabase a PostgreSQL Nativo en AWS:** Para la fase de prototipo y MVP se empleó Supabase por velocidad de iteración. No obstante, al escalar a nivel de producción masiva, las plataformas propietarias BaaS incrementan los costos. La arquitectura de producción de NEXIA escala sobre **PostgreSQL en AWS (RDS / Aurora Serverless v2)** complementado con **AWS Lambda / ECS Fargate** para tareas asíncronas, reduciendo el costo de base de datos y backend a una fracción mínima.
- **Inferencia de IA Real y Eficiente (Gemini Flash Multimodal):** El consumo de tokens en modelos optimizados de Google Gemini cuesta **$0.00002 USD por segundo de video** ($0.0012 USD por minuto). Auditar un incidente escolar típico de 15 minutos cuesta escasos **$0.018 USD** (menos de $90 COP). Incluso con 100 incidentes mensuales y muestreos de centinela, el costo de inferencia no supera los **$15 a $25 USD/mes**.
- **Exclusión de WhatsApp del Costo Base:** Para no inflar innecesariamente el valor base del servicio, la mensajería automatizada por Meta Cloud API se mantiene como módulo opcional (Fase 2). En la versión núcleo, las notificaciones y radicados se gestionan nativamente en la plataforma web y por correo electrónico.

2. Comparativa de las 3 Opciones de Escalamiento

A continuación se detallan los 3 escenarios de despliegue del proyecto, destacando la **Opción 2** como el modelo estándar y recomendado para implementación inmediata:

Escenario / Opción	Arquitectura de Despliegue	Costo Técnico Operativo	Precio de Venta Sugerido (Colegio)
Opción 1: MVP si Escala (PaaS Actual)	• Supabase Pro (Postgres + Auth gestionado) • Render Cloud Web Service • Gemini Flash API por demanda • Almacenamiento local del colegio	**$110 - $145 USD / mes** (~$440K - $580K COP)	**$2.200.000 COP / mes** (~$550 USD/mes) *(Margen limitado por sobrecosto de servicios PaaS)*
Opción 2: Producción Escalada (OPCIÓN BASE RECOMENDADA)	• **PostgreSQL en AWS (RDS / Aurora)** • **AWS Lambda / ECS Fargate** (cómputo por demanda) • **Inferencia Gemini Flash Multimodal** • **Almacenamiento en NVR local del colegio** ($0 cloud storage)	**$45 - $65 USD / mes (~$180K - $260K COP)** **Ahorro técnico del 55%**	**$1.400.000 COP / mes (~$350 USD/mes)** **Anual (15% dto): $14.280.000 COP / año (~$3.570 USD/año)**
Opción 3: Escalando + Nuevas Funciones (Campus Enterprise)	• Todo lo de la Opción 2 en AWS • **Módulo WhatsApp Meta Cloud API** • Centinela predictivo de aforos en tiempo real • Auditoría perimetral de intrusión nocturna	**$95 - $130 USD / mes** (~$380K - $520K COP)	**$2.400.000 COP / mes** (~$600 USD/mes) **Anual (15% dto): $24.480.000 COP / año** (~$6.120 USD/año)

3. Desglose Detallado de Costos de Infraestructura (Opción 2 — Producción en AWS)

El siguiente cuadro desglosa la inversión mensual y anual que requiere la infraestructura técnica para atender a un colegio estándar (20 cámaras, doble jornada escolar):

Rubro Técnico	Detalle de Consumo y Dimensionamiento	Costo Mensual	Costo Anual (12m)
Inferencia de IA (NEXIA Vision)	Google Gemini Flash Multimodal (~$0.0012/min de video). Estimado para 80 a 100 incidentes mensuales de 15 min + muestreo preventivo.	$18 - $25 USD (~$72K - $100K COP)	$216 - $300 USD (~$864K - $1.2M COP)
Base de Datos en AWS	PostgreSQL en AWS RDS (instancia db.t4g.micro reservada con almacenamiento SSD gp3 y copias de seguridad automáticas diarias).	$20 - $28 USD (~$80K - $112K COP)	$240 - $336 USD (~$960K - $1.34M COP)
Cómputo Backend & Lambdas	AWS Lambda (ejecución serverless de APIs) + AWS API Gateway + tareas asíncronas de auditoría en AWS ECS Fargate.	$12 - $18 USD (~$48K - $72K COP)	$144 - $216 USD (~$576K - $864K COP)
Almacenamiento de Video	**Gestión en NVR/DVR local de la institución** (Acceso seguro vía protocolo RTSP local sin costo de almacenamiento en nube).	**$0 USD** **(Cubierto por colegio)**	**$0 USD** **(Cubierto por colegio)**
TOTAL TÉCNICO NETO (Opción 2)	**Costo directo de infraestructura por colegio**	**$50 - $71 USD / mes** **(~$200K - $284K COP)**	**$600 - $852 USD / año** **(~$2.4M - $3.4M COP)**
Salvedad: Almacenamiento Cloud Opcional	*Solo si el colegio no posee NVR y exige custodia en AWS S3 (retención rotativa 30 días, ~6 TB a 15 TB comprimidos).*	*+$145 a $240 USD*	*+$1.740 a $2.880 USD*

Margen y Viabilidad Comercial: Al vender el servicio a **$1.400.000 COP mensuales** frente a un costo técnico de **~$240.000 COP**, NEXIA obtiene un margen bruto superior al **80%**, permitiendo financiar soporte técnico continuo, mesa de ayuda, mantenimiento preventivo y capacitaciones presenciales al Comité de Convivencia Escolar (Ley 1620 de 2013).

4. Ficha Técnica de Tecnologías Utilizadas en NEXIA

La arquitectura de NEXIA combina tecnologías web de alto rendimiento con servicios en la nube optimizados para escalabilidad institucional:

Capa Arquitectónica	Tecnología Seleccionada	Función Específica y Justificación de Ingeniería
Frontend SPA	React 19 + Vite	Renderizado ultra veloz en cliente, bajo consumo de batería en dispositivos móviles y panel responsivo para directivos y estudiantes.
Backend API	FastAPI (Python 3.12 Asíncrono)	Framework de alto rendimiento asíncrono. Maneja peticiones no bloqueantes y orquesta tareas en segundo plano (BackgroundTasks).
Base de Datos Relacional	PostgreSQL + SQLAlchemy 2.0	Persistencia robusta con integridad referencial, eliminación en cascada de evidencias y compatibilidad directa con AWS RDS / Aurora.
Validación de Esquemas	Pydantic v2	Tipado estricto y sanitización de datos de entrada en radicados, previniendo vulnerabilidades y asegurando coherencia en fechas y horas.
Seguridad & Autenticación	JWT + Bcrypt (Passlib)	Control de acceso basado en roles (RBAC: Estudiante, Acudiente, Administrador) y almacenamiento criptográfico irreversible de credenciales.
Motor de Visión IA	Gemini Flash Multimodal	Inferencia multimodal sobre fotogramas y video para cotejar reportes frente a grabaciones reales de cámaras (Ley 1620).
Transmisión Directiva	WebRTC / MediaStream API	Canal de baja latencia para que el personal de seguridad y directivos puedan enlazar cámaras móviles a la matriz escolar en tiempo real.
Generación de Expedientes	ReportLab Engine	Compilación automatizada de dictámenes periciales y propuestas en formato PDF formal con firma institucional.

5. Puntos Clave de Defensa para la Exposición

Al presentar el proyecto, los siguientes 4 argumentos sustentan la viabilidad técnica y financiera ante preguntas del jurado:

1. **¿Por qué la Opción 2 y no el MVP?** *'Para el MVP usamos Supabase y Render para validar el concepto rápidamente, pero reconocemos que para escalar comercialmente, la arquitectura madura migra a PostgreSQL nativo en AWS con Lambdas, reduciendo el costo mensual de infraestructura a solo $50 - $70 USD.'*
2. **¿Cómo resuelven el costo masivo de almacenar video?** *'Los colegios ya tienen grabadores NVR y discos locales amortizados. NEXIA se conecta a esa infraestructura existente, por lo que el costo de storage en la nube es $0 USD. Si un colegio no tiene grabador, se ofrece el almacenamiento en AWS S3 como un paquete adicional transparente.'*
3. **¿Es costoso analizar video con Inteligencia Artificial?** *'No, porque utilizamos modelos multimodales Flash optimizados a nivel de tokens de video ($0.0012 USD/minuto). Analizar un incidente de 15 minutos cuesta menos de 100 pesos colombianos, haciendo el sistema 100% viable para cualquier institución.'*
4. **¿Cuál es el valor agregado frente a un sistema de cámaras tradicional?** *'Un sistema tradicional es pasivo y exige que alguien revise horas de video manualmente. NEXIA correlaciona los radicados de convivencia con el ángulo y horario exacto de la cámara en segundos, emitiendo un pre-dictamen objetivo que protege la identidad del alumno según la Ley 1620.'*